

# 基于半监督聚类的故障诊断与预测方法：案例研究

卡迈勒·阿扎尔 (Kamyar Azar) a、佐尔雷·哈吉阿洪迪-梅博迪 (Zohreh Hajiakhondi-Meybodi) b、法尔努什·纳德哈尼 (Farnoosh Naderkhani) a, \*

a 加拿大蒙特利尔康考迪亚大学信息系统工程研究所 b 加拿大蒙特利尔康考迪亚大学电气与计算机工程系

## 摘要

近年来，工业人工智能（IAI）的热潮兴起，加之智能传感器技术的进步，使得多种状态监测（CM）技术同时应用于制造/工业领域。智能利用状态监测数据有助于提升制造系统的安全性、可靠性和可用性。然而，传统的系统监测技术无法有效处理如此丰富的状态监测信息。对此，本文提出了一种新颖的混合维护决策支持系统（MDSS），用于考虑事件触发型状态监测数据的故障诊断与预测。该维护决策支持系统是一种混合框架，通过融合基于机器学习（ML）的模型与统计技术构建而成。具体而言，该系统是一种时变比例风险模型（PHM），结合了半监督机器学习方法和强化学习（RL），旨在为遭受随机退化的系统寻找以成本最小化为目标的最优维护策略。所提出的混合模型能够以自适应、自主的方式推断和融合海量状态监测数据源，无需人工干预即可推荐最优维护决策，这在维护领域是一项突破性贡献。为验证所提模型的结构和性能，基于美国国家航空航天局（NASA）提供的包含航空发动机全寿命周期数据和状态监测数据的数据集，开发了一系列全面的机器学习解决方案。

## 1. 引言

在当今竞争激烈的商业环境中，每家公司都迫切需要充分发挥自身潜力，以跟上竞争对手的步伐并稳固立足市场。随着工业物联网（IIoT）的发展与演进以及智能传感器技术的出现，状态监测（CM）数据变得易于获取。丰富的实时状态监测数据与机器学习（尤其是深度神经网络（DNNs））的进步相结合，使得智能、高效地监测工业系统并优化维护决策成为可能。工业物联网和工业人工智能的兴起，促使工业/制造领域部署智能自主生产系统。因此，状态监测数据能够得到更好、更高效的理解与处理。预计工业物联网和工业人工智能将很快成为所有希望在中取得成功、并与竞争对手保持同步或领先的企业的核心组成部分。此外，通过高效智能的预测与健康管理（PHM）系统，有望维持复杂系统的完整性。智能预测与健康管理系统的核心职责是通过持续监测系统、检测状态监测数据中的异常特征或趋势，并提出最优或近优的控制与维护措施，减少故障发生，从而降低成本。

基于上述工业物联网和工业人工智能的重要性，基于状态的维护（CBM）可被视为企业保持竞争优势的关键机制。基于状态的维护是最先进的维护策略，其利用状态监测数据跟踪底层系统的健康状态、预测潜在故障点并预防意外故障的发生。近年来，由于机器学习/深度神经网络和深度学习（DL）在分析和处理高维多模态流（HDMS）状态监测数据方面的独特能力，基于这些技术的基于状态的维护策略设计成为新的研究趋势[1]。尽管在预测性维护中应用机器学习/深度学习技术极具挑战性[2-4]，但该技

术潜力巨大，可带来诸多显著效益，例如提高资产可用性和可靠性、降低资本支出（通过提升资产可用性可减少设备数量）以及降低运营费用（如更换成本）。一般而言，基于状态的维护主要包含三个核心组件：（i）数据采集；（ii）数据处理；（iii）维护决策制定[5]。尽管前两个组件近年来已得到广泛研究，但从中提取的信息却很少能被有效转化并应用于维护决策制定。本文旨在通过提出一种新颖的维护决策支持系统来填补这一空白，该系统采用基于半监督聚类的故障诊断与预测方法，并结合强化学习寻找最优策略。

## 2. 相关工作

本节将综述机器学习和深度学习在基于状态的维护中的应用、维护决策模型以及现有模型的局限性，并阐述所提模型的创新性与贡献，最后介绍论文的组织结构。

### 2.1 文献综述

基于深度学习的剩余使用寿命（RUL）预测近年来受到广泛关注。利用机器学习/深度学习模型预测剩余使用寿命是该领域的最新研究方向之一。例如，文献[7]中基于NASA提供的公开数据集[6]，采用深度双向长短期记忆（BiLSTM）模型估算燃气涡轮发动机的剩余使用寿命。作者通过与多层感知器

（MLP）和支持向量回归（SVR）等其他模型的对比，验证了该模型的良好性能。文献[8]提出了一种双任务深度长短期记忆（LSTM）模型，通过联合学习退化阶段评估和剩余使用寿命预测，获得了更稳健、准确的结果。文献[9]提出了一种基于卷积神经网络（CNN）的深度学习方法来估算剩余使用寿命，经与其他方法对比，证实了该模型的有效性和优越性。文献[10]开发了一种基于相似度插值

（SBI）的数据驱动方法来估算剩余使用寿命。该方法首先将高维传感器测量数据转换为反映系统退化状态和健康状况的一维健康指数（HI），然后利用相似度插值法估算剩余使用寿命。与传统的循环神经网络（RNN）自编码器模型相比，基于双向循环神经网络自编码器的模型能更稳健地计算健康指数值。此外，该研究还提出了一种特定领域规则，以提高剩余使用寿命预测的准确性。除了提出一种新颖的一维健康指数外，施（Shi）和谢哈代（Chehade）[11]还开发了一种双长短期记忆网络，能够检测系统开始退化的突变点。作者指出，突变点检测具有重要意义，因为在突变点之前预测剩余使用寿命是不合理的，且该阶段的数据无法提供有价值的信息。文献[12]综述了该领域的研究现状和未来机遇，更多相关参考文献可参见[13-18]。尽管现有研究结果具有良好的预测精度，但仅依靠剩余使用寿命估算而未设计相应的决策支持系统，并不足以支持维护决策制定。此外，虽然剩余使用寿命能提供有用信息，但仅基于其数值做出决策并不充分。这是因为在现有文献中，大量研究专注于剩余使用寿命估算，却忽略了在某些系统（尤其是故障可能导致灾难性后果的系统）中，更需要预测机器或系统在下次检查间隔内无故障运行的概率。在这类系统中，仅依靠故障发生前的剩余时间（即剩余使用寿命），维护人员无法判断检查间隔是否合理。相比之下，“风险率”是一种更充分的衡量指标，能够解决上述问题。此外，剩余使用寿命可通过风险率计算得出，但反之则不成立。

现有基于状态的维护研究涵盖了统计方法和机器学习方法。传统的统计基于状态的维护模型（如马尔可夫决策过程（MDP））已被广泛应用于维护优化领域，用于制定最优维护策略。比例风险模型

（PHM），又称考克斯比例风险模型（Cox's PHM），是生存分析中常用的模型，可用于构建和估算风险率。该模型同时考虑了系统寿命（即基准风险）和系统退化（即风险隐患）。在传统的考克斯比例风险模型中，与风险率和系统退化相关的协变量被假设为不随时间变化。而时变考克斯比例风险模型中的协变量则可随时间变化，其参数可通过统计方法估算，进而获得最优维护策略。该领域的早期

研究包括文献[19,20]，其在半马尔可夫决策过程（SMDP）框架下推导了最优更换策略。该研究考虑了具有右连续随机协变量过程的考克斯比例风险模型，并在周期性维护场景下，通过开发递归算法最小化系统的长期期望平均成本。文献[21]放松了之前的离散时间近似假设，提出了基于比例风险模型的退化系统最优策略。文献[22]首次采用含时间效应的自回归模型构建系统退化模型，基于该模型推导了平均剩余寿命（MRL），并通过在半马尔可夫决策过程框架下构建决策问题，确定了不同检查策略下以系统长期成本最小化为目标的最优维护策略。文献[23]基于隐马尔可夫模型（HMM）设计了一种两级成本最优贝叶斯控制图，用于机械设备的早期故障检测。该研究考虑了相关性故障模式（即退化故障和灾难性故障）：灾难性故障可能在系统运行过程中的任何时刻发生，而退化故障仅在系统处于非健康状态的停留时间结束后发生。为建模这种故障相关性，假设在健康状态下，灾难性故障时间和停留时间的联合分布服从马歇尔-奥尔金双变量指数分布。该研究在半马尔可夫决策过程框架下求解了所提控制图的优化问题，并采用贝叶斯方法计算平均剩余寿命。为验证模型性能，作者利用铣床的真实多变量数据集进行实验，并与单采样间隔和单控制限模型进行了对比。文献[24]针对易发生轻微故障或灾难性故障的系统，提出了一种基于动态阈值（而非恒定阈值）的基于状态的维护策略。该研究假设在每个检查周期内存在三种维护动作（即不维护、不完全维护和预防性更换），并在半马尔可夫决策过程框架下开发了一种改进的策略迭代算法来求解优化问题。文献[25]全面综述了基于状态的维护模型，重点关注数学建模和优化方法。文献[26]提出了一种面向国防应用的最优维护策略，是比例风险模型框架下基于状态的维护方法的另一应用实例。更多相关参考文献可参见[27-31]。

传统上，基于考克斯比例风险模型的维护策略和决策支持系统本质上是统计性的。然而，随着海量状态监测数据和高维多模态流传感数据的可获得性提升，统计方法已难以应对当今的大多数问题。这是因为统计方法适用于输入数据和特征较少的场景，而当输入数据量和特征数量增加时，统计方法难以处理数据中固有的关联关系。具体而言，考克斯比例风险模型的统计解决方案在处理高维、多类型数据时面临严峻的分析挑战，且随着输入数据量的增加，统计方法的计算耗时显著增加。此外，大多数统计方法通常依赖于一些不切实际的预设假设，导致其在实际问题中的应用受到限制。如前所述，现代制造系统的复杂性以及多模态状态监测数据的指数级增长，使得传统模型难以适用。这推动了一系列基于先进人工智能/机器学习算法的维护决策支持系统研究。强化学习（RL）是基于状态的维护优化中应用最广泛的机器学习方法之一，其核心思想是学习者（或智能体）通过与环境的交互，学习在系统的每个状态下应采取的动作。例如，文献[32]提出了一种基于强化学习的长期路面维护规划最优策略。作者指出，由于状态-动作空间规模庞大，传统动态规划等方法计算耗时且效率低下。因此，该研究首先采用主成分分析（PCA）降低状态空间维度，然后构建人工神经网络（ANN）近似Q值函数。通过调整超参数，获得了包含15年维护规划期内多种维护处理方式的最优维护策略。类似地，文献[33]将深度强化学习（DRL）模型应用于桥梁维护，以获取最优维护策略（桥梁包含大量组件）。由于状态-动作空间具有无限性，动态规划方法无法求解该问题。因此，作者采用卷积神经网络（CNN）作为非线性近似器，学习状态-动作Q值，并指出该网络可通过大量历史数据或仿真数据进行训练，且状态转移概率可通过仿真和历史数据获得。文献[34]提出了一种基于强化学习的非表格化解决方案，用于电网的最优运行与维护（O&M）调度。该方案将Q学习与人工神经网络集成相结合，适用于高维状态-动作空间的大型系统。更多相关研究可参见[35-39]。在这类问题中，由于状态-动作空间呈指数级增长，通常需要采用维度降低技术（如主成分分析）或无需维度降低的基于状态的维护深度强化学习方法。具体而言，深度强化学习融合了深度学习技术，通过将策略或其他学习函数表示为神经网络，高效求解高维马尔可夫决策过程。本文提出了一种利用风险率进行维护决策的替代方法，该方法仅依赖于两个



因素：基准风险和风险隐患。所提模型融合了所有可用的状态监测数据，构建最优维护决策支持系统，因此无需维度降低技术，且不会受到维度灾难的影响。

## 2.2 创新性与贡献

本文提出了一种基于考克斯比例风险模型的半监督聚类维护决策框架。具体而言，结合统计方法和机器学习算法，提出了一种高效、新颖的混合半监督模型，用于考虑状态监测数据的故障诊断与预测。在该模型中，首先计算时变考克斯比例风险模型的两个核心组件：考虑系统寿命的基准风险（BH）函数和纳入状态监测数据的风险隐患（HR）函数。由于缺乏标记数据，采用半监督方法基于系统寿命和传感器测量数据估算系统状态。因此，所有状态监测数据均用于构建聚类，然后基于聚合聚类定义状态空间及其相关转移概率。将聚合聚类方法得到的结果输入强化学习/深度强化学习模块，形成闭环以最小化总成本。所提框架无需依赖数据的先验知识和预设假设，具有优异的实际应用性能，且计算复杂度低，对数据的维度、多样性和模态敏感性低。该模型可为开发智能维护决策支持系统奠定基础，该系统能够通过传感器监测系统、分析系统状态并自主制定最优维护决策，无需人工干预。综上，本文的贡献可总结如下：

- 提出了一种基于半监督聚类和强化学习/深度强化学习的框架，用于有效解读和合理利用状态监测数据及系统寿命信息，实现故障诊断与预测。
- 利用风险函数设计了一种替代维护模型，与剩余使用寿命相比，该模型具有更强的泛化性和充分性。
- 开发了一种创新方法，无需领域特定知识或耗时、成本高昂的假设即可估算系统状态。

## 2.3 论文结构

本文其余部分组织如下：第3节阐述问题描述；第4节介绍所提决策支持系统开发所用的数据集及相关背景知识；第5节详细描述所提混合半监督机器学习维护决策支持系统框架；最后，第6节对全文进行总结。

## 3. 问题描述

如前所述，基于状态的维护是最先进的维护策略，其利用状态监测数据跟踪系统健康状态、预测设备故障并预防高成本故障的发生。本文考虑的机器或系统易发生随机退化和随机故障（可能在任何时刻发生）。系统健康状态通过部署在系统中的传感设备进行监测，这些设备会随时间产生大量传感器测量数据和信号。收集到的状态监测数据需要经过处理和分析，以支持合理的维护决策。状态监测数据具有多种格式，如数值型、波形型（如振动信号）和高维型（如图像序列）。本文提出了一种基于机器学习的故障诊断与预测模型，该模型利用原始状态监测数据，基于系统状态制定维护决策。假设系统存在三种可区分的状态：健康状态、预警状态和故障状态。当系统进入不同状态时，需采取相应的维护动作：若系统处于健康状态，则无需采取任何动作；若处于预警状态，则执行预防性维护或轻微修复；若进入故障状态，则执行纠正性维护。

以上为问题描述。接下来，将介绍所提维护决策支持系统框架开发和评估所用的数据集。需要再次强调的是，如第1节所述，基于该数据集的深度神经网络/机器学习建模目前主要集中在剩余使用寿命预

测，但仅依靠剩余使用寿命而未设计相应的决策支持系统，并不足以支持维护决策制定。本文旨在填补这一空白。

## 4. 数据集与背景知识

本节首先简要介绍所提半监督维护决策支持系统框架开发所用的数据集，然后概述考克斯比例风险模型和设计该框架所用的机器学习模型。

### 4.1 数据集描述与预处理

商用模块化航空推进系统仿真（CMAPSS）数据集是预测与健康管理领域应用最广泛的数据集之一。该数据集由NASA提供，包含航空发动机的全寿命周期数据，分为四个子集（FD001、FD002、FD003和FD004）。本文使用了这四个子集，每个子集均划分为训练集和测试集。系统每个组件均安装了21个传感器以收集状态监测数据，共包含100台运行中的发动机（易发生随机故障）。每个子集的数据模拟了三种运行条件下的多种退化行为场景。表1展示了发动机9的21个传感器测量数据的描述性统计结果。数据预处理主要包括两个步骤：（i）传感器选择；（ii）归一化，具体如下：

表1 CMAPSS数据集描述性统计结果

传感器ID	均值	标准差	最小值
SM1	518.67	0.00	518.67
SM2	642.68	0.50	641.21
SM3	1590.52	6.13	1571.04
SM4	1408.93	9.00	1382.25
SM5	14.62	0.00	14.62
SM6	21.61	0.00	21.60
SM7	553.37	0.89	549.85
SM8	2388.10	0.07	2387.90
SM9	9065.24	22.08	9021.73
SM10	1.30	0.00	1.30
SM11	47.54	0.27	46.85
SM12	521.41	0.74	518.69
SM13	2388.10	0.07	2387.88
SM14	8143.75	19.08	8099.94

SM15	8.44	0.04	8.32
SM16	0.03	0.00	0.03
SM17	393.21	1.55	388.00
SM18	2388.00	0.00	2388.00
SM19	100.00	0.00	100.00
SM20	38.82	0.18	38.14
SM21	23.29	0.11	22.89

**传感器选择：**由表1可知，部分传感器的测量数据随时间保持恒定或标准差极低，因此这些传感器被排除在模型之外。最终选择了14个传感器：SM2、SM3、SM4、SM7、SM8、SM9、SM11、SM12、SM13、SM14、SM15、SM17、SM20和SM21。

**归一化：**由于不同传感器测量数据的取值范围存在差异，较大的数值可能会对模型产生显著影响，导致最终结果出现偏差。因此，为获得一致的结果，深度学习/机器学习模型在训练前通常需要进行归一化处理[40]。归一化可将每个特征缩放至相同的取值范围，从而提高训练速度。但需注意的是，归一化会改变数据的原始尺度，可能增加结果解读的难度。综合考虑归一化的显著优势，本文采用归一化数据进行模型训练。归一化基于以下公式实现：

❗ Invalid equation

其中， $X_i$  和  $X'_i$  分别表示第  $i$  个传感器测量数据归一化前后的数值。

以上为数据集描述与预处理步骤。接下来，简要概述考克斯比例风险模型。

4.2 考克斯比例风险模型

如前所述，风险率可作为维护决策制定的充分衡量指标。考克斯比例风险模型是估算风险率的常用模型，其表达式如下：

$$h(t, Z(t)) = h_0(t) \times g(Z(t)), (2)$$

其中， $h_0(t)$  表示基准风险，反映系统寿命对故障的影响； $g(\cdot)$  表示风险隐患，反映协变量的影响。基准风险和风险隐患可分别通过威布尔分布和指数分布建模，具体如下：

$$h(t, Z(t)) = \frac{\beta}{\eta} \left(\frac{t}{\eta}\right)^{\beta-1} \times \exp\left(\sum_i \lambda_i \times z_i(t)\right),$$

其中， $\beta$  和  $\eta$  分别为拟合威布尔分布的形状参数和尺度参数； $z_i(t)$  表示第  $i$  个协变量在时刻  $t$  的取值； $\lambda_i$  为对应的系数。

通过将故障数据拟合威布尔分布，可估算出形状参数和尺度参数，结果如下：

$$\hat{\beta} = 4.409, \hat{\eta} = 225.026. (4)$$

由于  $\beta > 1$ ，风险函数呈递增趋势，表明系统随时间不断退化。对于易磨损的系统，应执行预防性维护（PM）以恢复系统健康状态，降低故障风险。此外，在实际场景中，故障更换成本通常高于预防性维护成本，因此采用预测性维护策略是合理的。通过采用预测性维护策略，可减少预期故障次数，从而降低故障更换的预期成本，提高系统的长期可靠性和可用性。

需要说明的是，尽管  $\beta$  值较高，但执行预防性维护仍然是一种有效的维护策略。根据文献[41]，预防性更换动作（即在设备发生故障前采取的动作）需满足两个必要条件：（i）故障更换的总成本高于预防性更换成本；（ii）设备的风险率呈递增趋势。在基于状态的维护文献中，已有多项研究在  $\beta$  值较高的情况下考虑预防性维护动作。例如，文献[42]和[43]中估算的  $\beta$  值分别为4.9和[4.03-8.97]；文献[44]采用基于威布尔分布和深度信念网络的方法评估轴承的性能退化，其估算的形状参数为5.067；文献[45]为海上风电场的四个不同组件开发了机会性基于状态的维护策略，其中两个组件的估算形状参数为3；文献[46]提出了另一种海上风力发电机基于状态的维护方法，系统中四个组件中有三个的估算形状参数为3；文献[47]提出了一种面向易发生软故障和硬故障的系统的基于状态的维护策略，其中硬故障风险率通过基准风险函数服从威布尔分布的比例风险模型描述，其估算形状参数为4.63。所提强化学习方法的结果也验证了上述结论。

模型系数通过时变考克斯比例风险模型框架下的统计方法（最大似然估计（MLE））估算。需要说明的是，参数估算是基于Python的生存分析库“lifelines”实现的[48]。具体而言，采用“CoxTimeVaryingFitter”函数拟合时变考克斯比例风险模型，该函数结合了 Breslow 估计[49]，同时考虑了寿命和协变量的影响。

此外，监督学习模型的开发需要提取特征以预测特定标签。因此，特征工程（即提取和选择合适的特征集）是该过程中最关键的环节。在本文中，基准风险和风险隐患的选择是特征工程的一部分，具体而言，基准风险和风险隐患被用作模型的特征。模型系数的估算结果如表2所示。为直观展示，图1给出了第11台发动机的风险率以及基准风险与风险隐患的关系。由图可知，风险率随时间呈递增趋势。下一步将基于计算得到的风险率，利用机器学习算法开发维护模型。

表2 CMAPSS数据集的系数估算结果

传感器ID	估算值 $\lambda_i$
SM2	1.424
SM3	0.021
SM4	0.145
SM7	-0.898
SM8	-1.698
SM9	-0.010
SM11	4.497
SM12	-1.647

SM13	6.201
SM14	0.026
SM15	3.394
SM17	0.245
SM20	-4.873
SM21	-3.720



(a) 第11台发动机的风险率 (b) 第11台发动机的基准风险（BH）与风险隐患（HR）的关系

4.3 半监督机器学习模型

机器学习是人工智能的一个分支，其利用计算统计方法使机器和计算机能够从数据中自动学习，而无需显式编程。随着计算能力的提升和状态监测数据的丰富，机器学习已成为解决各类问题的强大工具。一般而言，机器学习模型可分为监督学习和无监督学习技术。由于CMAPSS数据集没有系统状态标签，监督学习模型无法直接应用。因此，本文采用改进的K均值算法（无监督学习算法）构建标签。由于标签是定性的，后续将训练分类模型基于风险率预测系统状态。现有文献中存在多种常用的分类算法，本文训练了部分主流分类模型，简要概述如下：



1. **传统机器学习模型**：传统机器学习模型包括K近邻（KNN）、支持向量机（SVM）和朴素贝叶斯等。这些模型易于实现，且相比其他类型的分类模型具有更强的可解释性和更低的复杂度。
2. **集成学习模型**：集成学习模型是一种元算法，其融合多个异质或同质的基础机器学习模型的结果，以提高预测精度并降低预测方差。集成学习模型包括多数投票、堆叠和随机森林等。与传统机器学习模型相比，集成学习模型复杂度更高、实现难度更大，但能够融合多个模型的结果，提供更准确的预测性能。本文提出的三种集成模型的详细描述如下：

(a) **多数投票**：该方法中，多个模型对每个数据点进行预测，每个模型的预测结果视为一票，最终预测结果由多数模型的预测决定。

(b) **堆叠**：堆叠是另一种集成模型，其融合异质或同质机器学习模型的不同预测结果。该算法包含两个层次：第一层中，多个基础模型对每个数据行进行预测；第二层中，将基础模型的预测结果作为元学习器的输入。换句话说，元学习器将基础模型的预测结果视为新特征，以融合所有基础模型的信息。本文采用逻辑回归作为元学习器。逻辑回归通过预测数据属于某一类别的概率，并利用回归模型的思想进行分类。由于回归模型的输出可能超出[0,1]区间，无法直接用于分类问题。为确保输出落在[0,1]区间，需采用sigmoid函数进行转换，具体如下：

$$p(X) = Pr(Y = 1|X) = \frac{\exp(B^T \cdot X)}{1 + \exp(B^T \cdot X)}$$

其中， $Pr(Y = 1|X)$  表示在观测到  $X$  的情况下，响应变量  $Y$  属于第一类的概率； $B$  为模型系数或参数。这种单调转换也称为  $p(X)$  的对数几率转换。本文采用交叉熵损失函数而非均方误差（MSE）来估算模型参数，交叉熵损失函数的表达式如下：

$$C(\theta) = -\frac{1}{N} \sum_{i=1}^N (\log(h_{\theta}(x_i)) + \log(1 - h_{\theta}(x_i))).$$

通过对计算得到的概率设置决策阈值，可对每个数据进行分类。例如，设置阈值为0.5：若概率小于0.5，则数据属于第一类；若概率大于0.5，则数据属于另一类。

(c) **随机森林**：随机森林是一种集成学习方法，其以分类树或回归树作为基础学习器。该算法由多个决策树组成，每个决策树在构建过程中通过对观测数据进行随机采样，并在节点分裂时选择随机/有限的属性子集进行训练。对于回归问题，随机森林的最终决策由每个树的输出平均值决定；对于分类问题，最终决策由多数投票决定。

**3. 深度学习模型：**深度学习模型是近年来兴起的一类机器学习模型，包括卷积神经网络（CNN）、长短期记忆网络（LSTM）和前馈神经网络（FFNN）等。由于深度学习模型能够从原始数据中提取有用信息和高级特征，其已成为人工智能领域的最新研究热点，因此也适用于系统健康状态评估。与集成学习模型类似，深度学习模型预测精度更高，但可解释性较差且训练耗时更长。一般而言，深度学习模型由多个称为人工神经元的模块或单元组成，通过最小化损失函数进行训练。在每个epoch中，一批数据通过网络进行前向传播和反向传播，每个epoch结束后更新网络参数以最小化损失函数。本文也训练了长短期记忆网络用于维护决策支持系统。长短期记忆网络是循环神经网络（RNN）的改进模型，能够解决梯度消失问题。长短期记忆网络包含一个长期细胞状态  $C_t$ ，用于决定哪些信息需要随时间保留，哪些信息需要遗忘。每个长短期记忆细胞的输入包括时刻  $t$  的数据点  $x_t$  和前一个细胞的输出信息  $h_{t-1}$ 。信息流动通过三个门（遗忘门、输入门和输出门）进行控制：遗忘门决定哪些信息需要完全遗忘，哪些信息需要保留；输入门决定哪些新信息需要存储到细胞状态中；输出门决定哪些信息需要作为当前历史传递给下一个细胞。

## 5. 所提混合半监督框架

本节详细描述所提混合半监督机器学习维护决策支持系统框架。首先，第5.1节阐述如何基于含嵌入式K均值组件的半监督学习方法，从提取的特征（即基准风险和风险隐患）中构建标签；其次，构建标签后，训练监督模型将数据点分类到前一步定义类别中。本文训练了多种类型的分类模型，主要分为三类：（i）传统模型；（ii）集成学习模型；（iii）深度学习模型，具体将在第5.4节详细讨论。

### 5.1 标签构建阶段

分类模型是监督学习模型，因此需要输出标签。然而，CMAPSS数据集的传感器测量数据没有标签，因此需要自主构建标签（即健康状态、预警状态或故障状态）。本文利用聚类模型实现这一目标。聚类是一种无监督学习模型，其将数据聚类为不同的组，使得同一组内的数据点尽可能相似，不同组间的数据点尽可能不同。这一目标可通过最小化惯性或簇内平方和（WCSS）指标实现。现有文献中存在多种聚类算法，其中K均值聚类是该领域常用的算法之一，能够将数据划分为指定数量的组。本文采用三步半监督学习流程，并在不同步骤中利用K均值聚类将数据分为三类：健康状态、预警状态和严重退化/故障状态。具体步骤如下：

$$C_{BH} = \begin{cases} 1 & \text{基准风险处于健康状态} \\ 0 & \text{基准风险处于非健康状态} \end{cases}$$

$$C_{HR} = \begin{cases} 1 & \text{风险隐患处于健康状态} \\ 0 & \text{风险隐患处于非健康状态} \end{cases}$$

**1. 步骤1：基准风险和风险隐患的独立聚类：**采用K均值聚类将基准风险和风险隐患数据分别聚类为两个不同的簇（健康状态或非健康状态）：

其中， $C_{BH}$  和  $C_{HR}$  分别表示基准风险和风险隐患的聚类标签。基准风险和风险隐患的独立聚类结果如图2（a）和图2（b）所示。

**2. 步骤2：聚合聚类：**步骤1中，基准风险和风险隐患数据被独立划分为两个不同的簇。本步骤基于以下方法将这些簇聚合为一个单一簇：

- (1) 若基准风险和风险隐患被聚类到同一组（即均为健康状态或均为非健康状态），则最终聚类结果分别为健康状态或严重退化/故障状态；
- (2) 若基准风险和风险隐患被聚类到不同组（即基准风险为健康状态而风险隐患为非健康状态，或反之），则最终聚类结果为预警状态。

综上，所有可能场景的组合可表示为：

❗ Invalid equation

其中， $C_{Total}$  表示最终的聚合聚类标签。

**3. 步骤3：故障聚类：**由于发动机的故障时间跨度较大（128至362之间），部分早期故障的发动机可能没有严重退化/故障状态的数据。若直接训练分类模型，可能无法检测到这些潜在的早期故障。为解决这一问题，手动将每台发动机的最后  $d$  个全寿命周期数据标签改为严重退化/故障状态，即：

$$C_{Total} := \begin{cases} 0 & \text{最后 } d \text{ 个全寿命周期数据} \\ C_{Total} & \text{其他情况} \end{cases}$$

最终，每个聚类编号可作为下一步的标签。聚合聚类的最终结果如图3所示。

需要说明的是，独立考虑风险隐患和基准风险的合理性如下：考克斯比例风险回归模型可表示为  $h(t, Z(t)) = h_0(t) \times g(Z(t))$ ，其中  $g(Z(t)) = e^{\beta Z}$ 。风险率被视为仅依赖于设备寿命的基准风险率与依赖于随机过程  $Z$  取值的正函数  $g(Z(t))$  的乘积。因此，预测变量对预测风险率具有乘法或比例效应[50]。研究表明，最优决策是在状态监测检查完成后，当估算的风险率超过最优阈值时更换设备。基于上述数学原理，文献[50]构建了如下决策策略：每次检查时，获取关键风险因素（协变量）的取值，将这些测量值乘以其权重因子，组合形成复合协变量值（标记在r轴上），x轴表示检查时设备的寿命。

本文采用类似的思路，基于基准风险和风险隐患构建决策图：x轴表示发动机的运行寿命（由基准风险反映），r轴表示协变量的影响（由风险隐患反映）。将基准风险和风险隐患分离的思想源于“比例”风险模型的概念，该模型中提出了 $\beta$ 的部分似然函数，无需涉及基准函数。假设观测到发动机  $i$  的  $(X_i; \delta_i; Z_i)$ ，其中  $X_i$  为可能右删失的故障时间随机变量； $\delta_i$  为故障/删失指示符（1表示故障，0表示删失）； $Z_i$  表示一组协变量。令  $R(t) = X_i \geq t$  表示时刻  $t$  面临故障风险的发动机集合（风险集）。在比例风险假设下， $h(t, Z_t) = h_0(t)e^{\beta Z}$ ，因此部分似然函数可计算为：

❗ Invalid equation

由式（7）可知，部分似然函数与基准风险无关，仅利用故障时间的排序信息。此外，在大多数维护决策问题中，系统的真实状态是隐藏的，但状态监测数据包含了系统状态的部分信息。换句话说，通过融合状态监测（传感）数据，可在每个采样时刻部分观测到系统的真实状态。风险隐患依赖于瞬时测量值（因此包含了执行时刻系统真实状态的部分信息），融合风险隐患可形成非静态模型。本文提出利用无监督学习方法发现无标签数据中的隐藏模式（否则这些数据将无法被利用），并将数据分类为不同的组。因此，假设数据存在三种状态（健康状态、预警状态和故障状态），则同一状态或聚类中的观测数据的基准风险和风险隐患可能具有相似或接近的值。参数估算是所提框架特征工程阶段的一部分。所有经典机器学习模型都需要一定的特征，特征工程是机器学习模型的关键组成部分。即使是深度学习模型，其输入有时也需要经过工程化处理的特征。

## 5.2 基于强化学习的成本最小化

基于聚类方法得到的结果，本文实现了一种新颖的强化学习方法，形成闭环并设计以成本最小化为目标的维护决策支持系统。具体而言，开发了Q学习模型作为维护决策的优化工具。Q学习是一种无模型、基于价值的强化学习算法，用于学习给定状态  $s_t$  下动作  $a_t$  的Q值  $Q(s_t, a_t)$ 。每个时间片的Q值  $Q(s_t, a_t)$  更新如下：

$$Q(s_t, a_t) \leftarrow (1 - \lambda)Q(s_t, a_t) + \lambda(r_t + \gamma \max_{a_{t+1}} Q(s_{t+1}, a_{t+1})),$$

其中， $\gamma$  和  $\lambda$  分别表示折扣率和学习率； $r_t = R(s_t, a_t)$  表示状态  $s_t$  下执行动作  $a_t$  的奖励值。所开发的强化学习模型主要包含以下组件：

- (i) **智能体**：管理系统作为发动机的智能组件，充当智能体，基于一系列维护决策与环境交互。
- (ii) **状态空间**：状态空间与聚合聚类标签相关联，包括健康状态（ $s_t = 0$ ）、预警状态（ $s_t = 1$ ）和故障状态（ $s_f = 2$ ）。
- (iii) **动作空间**：智能体根据当前状态采取最优动作。动作空间对应维护操作，分为三个级别：不修复（ $a_t = 0$ ）、轻微修复（ $a_t = 1$ ）和重大修复（ $a_f = 2$ ）。
- (iv) **奖励**：奖励定义为维护成本。强化学习模型中最优策略的主要目标是选择最优维护动作，以最小化长期总成本（或等效最大化长期总奖励）。本研究，每个动作对应的奖励函数定义如下：

❗ Invalid equation

由于状态空间和动作空间的数量有限，采用Q学习方法更新每个状态下的状态-动作值函数，Q表的大小为  $(3 \times 3)$ 。为平衡探索与利用，采用 $\epsilon$ -贪婪动作选择策略，episode  $t$  中的  $\epsilon_t$  计算如下：

$$\epsilon_t = \epsilon_{min} + (\epsilon_{max} - \epsilon_{min}) \exp(\epsilon_d t), \quad (10)$$

其中， $\epsilon_{min}$ 、 $\epsilon_{max}$  和  $\epsilon_d$  分别表示最小探索率、最大探索率和探索衰减率。本研究中，假设  $\epsilon_{min} = 1/N_{total}$ 、 $\epsilon_{max} = 1$ 、 $\epsilon_d = 0.1$ ，其中  $N_{total}$  为总epoch数。仿真中，总epoch数设置为200，每个epoch包含400次迭代。学习率  $\lambda$  和折扣率  $\gamma$  分别设置为0.01和0.99。所提强化学习模型无需采用主成分分析等数据降维技术即可确定状态-动作空间。具体而言，将聚合聚类方法得到的结果输入强化学习模型：所有状态监测数据用于构建聚类，基于聚合聚类定义状态空间及其相关转移概率，最终输入强化学习模型以最小化总成本。

图4展示了所研究系统的状态-动作空间，包括三个状态（0、1、2）和三个动作（0、1、2）。任意时刻，发动机可在动作  $a$ （ $a \in 0, 1, 2$ ）的作用下从状态  $i$ （ $i \in 0, 1, 2$ ）转移到状态  $j$ （ $j \in 0, 1, 2$ ），转移概率为  $P_{i,j}^a$ 。图中，蓝色箭头表示选择“不修复”动作时从状态  $i$  到状态  $j$  的转移；绿色箭头表示执行“轻微修复”动作时的状态转移；红色箭头表示执行“重大修复”动作时的状态转移。例如， $P_{12}^0$  表示选择不修复动作（ $a = 0$ ）时，发动机从状态1转移到状态2的概率。考虑到实际场景中轻微修复的效果是不完全的（仅能使系统恢复到之前的状态，而非健康状态），绿色箭头表示轻微修复动作下的状态转移。最后，当系统进入吸收故障状态（状态2）时，执行重大维护动作，使系统恢复到健康状态（如图4中的红色箭头所示）。单位时间内从状态  $i$  到状态  $j$  的转移概率基于聚类结果计算如下：

$$P_{i,j} = \frac{n_{i,j}}{\sum_{k=1}^3 n_{i,k}}, \quad (11)$$



其中， $n_{i,j}$  表示当前状态为  $i$  且下一状态为  $j$  的观测数据总数。基于式（11），所研究系统的转移概率矩阵如下：

0.94533

0.05452

0.00015

0.13224

0.82936

0.03840

0.04433

0.04159

0.91408

(12)

假设轻微修复和重大修复的成本对应的奖励分别为-10和-40，强化学习的实现结果如表3所示。表3的第二列表示每个epoch中智能体采取的总动作数；最后两列表示系统达到稳态时，智能体采取的平均轻微修复动作数和平均重大修复动作数。由图5可知，稳态出现在第75个epoch（此时成本收敛），因此计算了第75至200个epoch期间的平均轻微修复动作数和平均重大修复动作数。

表3 强化学习方法的结果总结

总成本	总动作数	平均轻微修复动作数	平均重大修复动作
40.75	398.7125	0.5375	0.75

5.3 基于深度强化学习的成本最小化

本研究中，状态空间包含风险隐患（即连续状态空间）和对应的发动机寿命，共涉及100台发动机。在状态值为连续的情况下，无法直接使用Q表更新Q值。因此，采用深度学习模型近似状态-动作值函数。如图6所示，在Q网络上应用多层感知器（MLP）估算Q值，动作空间和奖励函数与前一节的案例研究完全相同。选择Q值最高的维护动作后，将该动作的相关信息存储到经验回放缓冲区  $D = e_1, \dots, e_t$ ，其中  $e_t = (\phi_t, a_t, r_t, \phi_{t+1})$ ； $\phi_t = [s_{t-\beta}, a_{t-\beta}, \dots, a_{t-1}, s_t]$  表示观测到的状态序列，包含时间片  $t - \beta$  至  $t$  之间的状态-动作对。随机选择回放缓冲区中的状态序列  $e_m$ ，基于随机梯度下降（SGD）方法更新学习模型的权重参数  $\xi_t$ 。给定  $\xi_r$ ，需要最小化损失函数  $L(\xi_t)$ （最优Q值与所选Q值的均方误差），其中  $L(\xi_t)$  的表达式如下：

$$L(\xi_t) = \mathbb{E}_{\phi_t, a_t, r_t, \phi_{t+1}} \left[ (Q_T - Q(\phi_t, a_t | \xi_{t-1}))^2 \right], (13)$$

其中，目标最优Q值  $Q_T$  表示为：

Invalid equation

给定状态  $s_t$ ，基于 $\epsilon$ -贪婪算法以概率  $(1 - \epsilon)$  选择最优动作  $a_t^*$ ，如下所示：

$$a_t^* = \arg \max_{a'_t} Q(\phi_t, a'_t). (15)$$

最后，计算所选动作对应的奖励  $r_t$ ，并将新的经验  $(\phi_t, a_t, r_t, \phi_{t+1})$  存储到回放缓冲区中。

基于深度强化学习的维护架构采用多层感知器模型，包含一个具有512个节点的隐藏层，激活函数为sigmoid。输入层和输出层的大小分别取决于状态空间和动作空间（输入层大小为2，输出层大小为3），输出层的激活函数为softmax。基于深度强化学习的维护模型共训练200个epoch。假设重大维护可使系统恢复到健康状态，当智能体选择重大修复动作（ $a = 2$ ）时，当前epoch终止。图7分别展示了基于深度强化学习的维护架构的累积奖励和维护成本。由图7（a）可知，随着epoch数的增加，累积奖励逐渐增加，表明模型训练效果良好。由图7（b）可知，尽管基于深度强化学习的模型能够实

现维护成本收敛，但存在以下缺点：（i）与基于强化学习的维护模型相比，深度强化学习模型的时间复杂度更高。主要原因是深度强化学习架构采用神经网络近似给定动作和状态的Q值，而非构建Q值表。由于该模型将连续的风险隐患作为状态，学习给定状态下的最优动作需要更长时间；（ii）仿真结果表明，深度强化学习模型的收敛性依赖于轻微修复的定义。例如，若轻微修复定义为使下一状态  $s_{t+1} = s_{t-5}$ ，则深度强化学习架构的成本无法收敛到稳态；（iii）尽管在深度强化学习设计中增加网络层数可能会提升模型性能，但维护成本无法在可接受的时间内收敛。

## 5.4 预测模型训练

所提维护决策支持系统框架的核心目标是设计和开发用于故障诊断/预测的混合框架，能够基于状态监测数据构建最优或近优的控制和维护策略，支持决策制定。因此，需要持续监测系统的风险率，以检测数据中可能指示过程或系统变化的异常情况。如前所述，对于风险率递增的系统，执行预防性维护是合理的。在适当的时间执行有效的预防性维护动作，可提高系统的可用性、可靠性和效率。

为设计此类智能系统，由于输出为分类变量，需要训练分类模型。本研究中，由于存在三个不同的类别（健康状态、预警状态和严重退化/故障状态），采用多分类模型。此外，构建预测模型后，需要关注每个模型的决策图。为避免数据泄露，首先将数据划分为训练集和测试集：每次运行时，选择80%的发动机数据作为训练集，其余作为测试集；然后基于第5.1节所述的流程，在训练集上拟合聚类模型；基于找到的聚类中心，转换训练集和测试集；聚类和标签构建完成后，在标签上训练不同的分类模型。如第4.3节所述，分类算法分为三类，其模型和结果将在第5.4.1、5.4.2和5.4.3节中详细讨论。

此外，由于过程中存在不确定性，同一模型在每次运行时可能会产生不同的结果。因此，采用10折交叉验证获取相关结果、预测的偏差和方差，并比较不同模型的性能。结果如表4所示，下文将详细讨论这些结果。

表4 训练准确率均值、标准差（SD）和测试准确率

模型	平均训练准确率	训练准确率标准差	测试准确率
含15棵树的随机森林	0.9856	0.0044	0.9826
堆叠分类器	0.9843	0.0049	0.9805
3近邻KNN	0.9819	0.0049	0.9782
1近邻KNN	0.9793	0.0052	0.9771
5近邻KNN	0.9825	0.0036	0.9768
4近邻KNN	0.9812	0.0034	0.9752
2近邻KNN	0.9764	0.0043	0.97
7次多项式核支持向量机	0.9695	0.018	0.9606
25批次大小、100轮训练的双隐藏层人工神经网络	0.9727	0.0102	0.9583

径向基函数（RBF）核且系数为scale的支持向量机	0.9728	0.0077	0.9569
10次多项式核支持向量机	0.9703	0.0161	0.956
多数投票（版本14）	0.9724	0.0073	0.9551
多数投票（版本19）	0.9716	0.0069	0.9541
6次多项式核支持向量机	0.9693	0.0049	0.9537
多数投票（版本10）	0.9732	0.0066	0.9528
5次多项式核支持向量机	0.9682	0.0048	0.9505
4次多项式核支持向量机	0.9689	0.0053	0.9479
3次多项式核支持向量机	0.9684	0.0086	0.9434
2次多项式核支持向量机	0.9607	0.0098	0.9349
逻辑回归	0.9507	0.0089	0.9305
径向基函数核且系数为auto的支持向量机	0.9525	0.0101	0.9291
Sigmoid核且系数为auto的支持向量机	0.9492	0.0091	0.9278
高斯朴素贝叶斯	0.9014	0.016	0.8847
补全朴素贝叶斯	0.6483	0.0342	0.6654
Sigmoid核且系数为scale的支持向量机	0.4013	0.0728	0.3974

### 5.4.1 传统模型结果

如前所述，传统模型包括机器学习领域的一些知名且常用的算法，如K近邻（KNN）和支持向量机（SVM）。这些模型具有不同的超参数，为获得最佳结果并比较其决策图，在不同超参数配置下训练每个模型。图8、9和10分别展示了不同超参数配置下K近邻、支持向量机和朴素贝叶斯的决策图。结果表明，3近邻KNN、7次多项式核支持向量机和高斯朴素贝叶斯在各自类别中表现最佳。

### 5.4.2 集成学习模型结果

集成学习是一种混合学习系统，其核心思想是训练多个基础模型（或弱学习器），并将它们的预测结果聚合为一个单一输出。通过应用集成模型，有望提高预测精度，获得更准确的结果。本文开发了三种集成模型：随机森林、多数投票和堆叠，结果如下：

**随机森林结果：**在树的数量范围[1,50]内训练随机森林模型。图11（a）和图11（b）分别展示了不同树数量下的10折交叉验证准确率和标准差。当树的数量为15时，模型取得最佳结果，其决策图如图11（c）所示。

**多数投票结果：**在相同的训练数据上训练不同的分类模型，每个模型对每个数据点进行预测，每个预测结果视为一票，最终数据点被分类到得票最多的类别。本文考虑了三种不同的场景：

- 1. 场景1：包含表4中的所有传统模型和随机森林；
- 2. 场景2：包含随机森林、1/3/5近邻KNN、逻辑回归、2/3/4/6/7次多项式核支持向量机、径向基函数核（系数为scale和auto）支持向量机、Sigmoid核（系数为auto）支持向量机和高斯朴素贝叶斯；
- 3. 场景3：包含随机森林、5近邻KNN、逻辑回归、2/3/4/5/6/7/10次多项式核支持向量机。

每个场景的决策图如图12所示。

**堆叠结果：**如第4.3节所述，与多数投票类似，分类问题的堆叠模型考虑异质基础模型。每个基础模型对每个数据点进行预测，这些预测结果作为元模型（或元学习器）的输入。本文选择3近邻KNN、7次多项式核支持向量机和15棵树的随机森林作为基础模型（基于结果选择的最佳模型），逻辑回归作为元模型。其决策图如图13所示。

### 5.4.3 深度学习模型结果

开发了两种深度学习模型：人工神经网络（ANN）和长短期记忆网络（LSTM）。图14展示了批次大小为25、训练轮数为100的人工神经网络模型，该网络包含两个隐藏层（每个层有6个节点），隐藏层的激活函数为双曲正切函数。长短期记忆网络是人工神经网络的改进模型，适用于分析序列数据（如时间序列）。由于全寿命周期数据可视为时间序列，因此长短期记忆网络适用于本研究（见表5）。训练了三种不同结构的长短期记忆网络模型：

由于长短期记忆网络模型依赖于时间和之前的传感器测量值，无法像其他模型那样绘制决策图，因此仅展示长短期记忆网络模型在数据集上的性能，结果如图15所示。需要说明的是，所有这些模型均基于FD001数据集开发。对其他三个数据集（FD002、FD003和FD004）也进行了类似分析，为节省篇幅，此处未列出，相关结果可根据要求提供。

表5 长短期记忆网络模型结构

模型结构	隐藏层数量	每个隐藏层的节点数	隐藏层激活函数
结构1	5	64	relu
结构2	5	64	tanh
结构3	5	128	relu
结构4	5	128	tanh
结构5	3	128	relu



结构6	3	128	tanh
结构7	3	64	relu
结构8	3	64	tanh

### 5.4.4 不同维护成本和策略下的性能评估

需要指出的是，在许多实际应用中，真实标签往往不可得。在这类应用领域，通常基于操作员和专家知识构建标签。例如，文献[51]基于重型卡车变速箱光谱油分析的真实数据集，开发了一种基于比例风险模型的更换维护策略。为计算所需的成本函数，需要定义金属颗粒（协变量）的随机行为（以发动机油中磨损金属颗粒的百万分比浓度（ppm）表示）。

由于缺乏真实标签，作者假设协变量表现为齐次马尔可夫过程，并确定了相应的转移概率矩阵。为确定两个基础协变量（铁和铜）的转移概率矩阵，将铁和铜的金属含量划分为5个区间，代表马尔可夫过程的状态。具体而言，铁的[0,15) ppm区间被视为状态0（健康状态）；[15,30) ppm区间被视为状态2，依此类推。状态分类和状态监测数据标签的确定基于专家知识。

CMAPSS数据集也面临类似的问题。本文提出聚合聚类方法的主要目的是解决对专家知识的依赖。为此，开发了一种基于机器学习的标签构建解决方案，无需人工干预。为验证所提模型的有效性，通过考虑不同的维护策略评估模型性能。需要说明的是，据作者所知，这是首个基于CMAPSS数据集的比例风险模型框架研究，因此无法直接与其他方法进行对比。因此，为验证所提模型，基于新开发的强化学习模型，以成本最小化为目标函数，在不同维护成本和策略下评估其性能。具体而言，在以下六种不同场景下进行性能评估：

1. 场景1：仅故障时更换（R-O-O-F）策略，故障成本  $C_F = 100$  ；
2. 场景2：仅故障时更换策略，故障成本  $C_F = 40$  ；
3. 场景3：仅故障时更换策略，故障成本  $C_F = 20$  ；
4. 场景4：执行轻微修复和重大修复，相关成本分别为  $C_{PM} = 20$  和  $C_F = 40$  ；
5. 场景5：执行轻微修复和重大修复，相关成本分别为  $C_{PM} = 20$  和  $C_F = 25$  ；
6. 场景6：执行轻微修复和重大修复，相关成本分别为  $C_{PM} = 20$  和  $C_F = 100$  。

结果如表6所示，得出以下结论：（i）结果表明，与仅故障时更换策略相比，预防性维护策略是最优维护策略，这与系统风险率随时间递增的特性一致；（ii）随着故障成本的增加，总成本相应增加；（iii）场景4中的平均轻微修复动作数少于场景6，这与所提模型的预期行为一致。其逻辑是：当故障成本增加而轻微维护成本固定时，系统为避免进入高故障成本的故障状态，更倾向于执行更多的轻微修复动作；（iv）当轻微修复和重大修复的成本接近时，系统将随机选择执行重大修复或轻微修复动作，这是合理的（如场景5）。

表6 不同维护成本和策略场景下的评估结果

场景	总成本	总动作数	轻微修复动作数

1	98.75	399.0125	0
2	45.5	398.8625	0
3	23.125	399.075	0
4	40.75	398.7125	0.5375
5	28.6875	398.725	0.6375
6	85.5	398.25	0.775

5.4.5 多单元系统的扩展

所提模型可修改应用于由异质功能元件组成的系统（称为多单元系统）。考虑一个包含  $n$  个组件的多单元系统（如供电系统），每个组件可能配备不同数量的传感器，即第  $i$  个单元可能配备  $n_i$  个传感器，用于测量指示该组件健康状态的特定协变量。之后，可为每个组件拟合  $n$  个不同的聚类模型，并提取聚类标签。在强化学习部分，需要重新定义状态：可通过两种场景和两种方法定义状态：（i）类似于聚类流程的第三步，聚合聚类标签，此时状态空间为一维；（ii）不进行聚合，独立使用每个标签，此时状态空间为  $n$  维。动作空间也需要相应调整，每个组件的动作数量取决于适用的维护动作类型，最终的动作空间是所有局部动作的可能组合的集合。

例如，考虑一个包含两个单元（ $n = 2$ ）的系统：第一个单元配备10个传感器，第二个单元配备20个传感器。首先，分别对第一个单元和第二个单元的传感数据拟合两个不同的K均值聚类模型，提取每个聚类模型的标签，记为  $S_1$  和  $S_2$ （ $S_1, S_2 \in 0, 1, 2$ ）。在定义强化学习状态空间的第一种场景中，可按如下方式聚合标签：

❗ Invalid equation

需要说明的是，这种聚合方式最为严格，因为每种组合都被视为一个不同的状态，但也可以简化。例如，可将状态定义为三类：

❗ Invalid equation

若采用第二种场景定义状态，则状态空间为二维数组（ $(S_1, S_2)$ ），无需全局聚合。最后，若每个单元考虑三种动作（即不动作、轻微修复和重大修复），则最终的动作空间包含9种不同的组合。

需要进一步说明的是，所提框架可应用于异质多状态系统。在这类场景中，传感器测量数据之间的变异性可能较大，或者部分传感器的测量类型可能不同。由于每个传感器的测量数据尺度不同，维护领域中经常出现高变异性问题。特征缩放是预处理步骤中的关键环节，能够解决这一问题。数据归一化和标准化是两种有效且简单的特征缩放技术，可将原始数据空间映射到所有特征具有相同尺度的新空间。对于不同数据类型的问题，需要在应用本文提出的方法之前进行一系列预处理，将所有数据转换为相同的域（格式）。总之，通过采用上述预处理技术，所提方法可应用于异质系统。

6. 结论

尽管基于NASA CMAPSS数据集的机器学习建模主要集中在剩余使用寿命预测，但本文认为仅依靠剩余使用寿命而未设计相应的决策支持系统，并不足以支持维护决策制定。为填补这一空白，本文提出了一种高效、新颖的混合维护决策支持系统框架，用于考虑状态监测数据的故障诊断与预测。所提维护决策支持系统模型是一种融合机器学习方法与统计技术的混合解决方案。该系统将系统状态划分为三种可区分的状态：健康状态、预警状态和故障状态。为找到最优维护策略，重点研究了结合半监督机器学习方法的时变比例风险模型。维护决策支持系统基于决策图监测系统的风险率，持续检测数据中可能指示过程或系统变化的异常情况。由于CMAPSS数据集的传感器测量数据没有决策标签，开发了一种直观的无监督流程，用于提取和构建所需的标签。为设计此类智能系统，构建了多种预测模型，每个模型都具有统一的决策图。本文采用并评估了多种机器学习模型，从传统机器学习模型到集成学习模型和深度学习架构。通过与不同机器学习算法的综合对比，验证了所提维护决策支持系统模型的有效性。

## 作者贡献声明

卡迈勒·阿扎尔（Kamyar Azar）：数据整理、调查研究、方法设计、软件开发、论文初稿撰写。

佐尔雷·哈吉阿洪迪-梅博迪（Zohreh Hajiakhondi-Meybodi）：数据整理、调查研究、方法设计、软件开发、论文修订与编辑。

法尔努什·纳德哈尼（Farnoosh Naderkhani）：概念构思、资金获取、调查研究、项目指导、论文初稿撰写、论文修订与编辑。

## 利益冲突声明

作者声明不存在可能影响本文研究结果的已知财务利益冲突或个人关系。

## 致谢

本研究部分得到加拿大科学与工程研究委员会（NSERC）通过NSERC探索基金（RGPIN 2019

（注：文档部分内容可能由 AI 生成）